缺失历史观测下的重尾概率预测：一项严格配对的实证研究

中文研究初稿

2026 年 9 月 11 日

摘要：历史观测缺失改变了预测器可利用的信息，点预测误差相近的模型仍可能给出不同的预测分布。如何把分布选择的作用与主干表示、缺失样本及训练随机性区分开，是评价概率预测的重要问题。
本文围绕这一问题建立固定历史掩码下的配对比较协议。在训练集统计量归一化、固定主干检查点和一致测试窗口下，比较 Gaussian、Laplace、固定自由度为 8 的 Student-t 与可学习自由度 Student-t。实验覆盖 ETTh1、Weather、Electricity，并以 TimePerceiver 和 PatchTST 分别考察分布头的作用。在随机缺失率为 0.3、预测长度为 96 的已核验实验中，固定 Student-t 相对 Gaussian 在两个主干的六组单种子配对中均降低 NLL 与 CRPS。TimePerceiver 上另有四个概率头种子的独立训练比较，可学习自由度 Student-t 在三个数据集上的平均 NLL 差值分别为 -0.043900、-0.473557 和 -0.074296。Electricity 上概率评分与点预测误差呈现不同方向，说明分布质量应与点预测性能联合评价。研究结果支持将重尾分布作为缺失历史预测的实证参照，并区分固定自由度证据与可学习自由度的训练稳定性证据。

关键词：时间序列预测；历史观测缺失；概率预测；Student-t 分布；配对评估

1 引言

多变量时间序列预测通常从一个完整历史窗口估计未来状态。传感器掉线、记录延迟或通道停用会使窗口中的部分信息不可用。缺失值的影响并不止于预测均值：同一个点预测偏差，在窄分布下可能意味着过度自信，在较宽分布下则对应不同的风险判断。因此，比较缺失历史预测器时，需要同时考察中心位置、分布形状和区间行为。

现有预测主干已形成多种有效的表示方式。PatchTST 将序列分块并采用通道独立建模 [2]；TimePerceiver 采用编码器与解码器框架处理时间序列预测 [1]。当这些表示保持不变时，预测头所作的分布假设能否改善概率评分，是一个可以直接检验的问题。本文不把标准 Student-t 分布重新定义为新模型，而是把输出分布作为受控因素，研究其在缺失历史输入上的效果。

这种比较容易受到实验协议的干扰。不同测试掩码会改变样本难度；重训主干会同时改变特征和输出头；把初始化为 8 的可学习自由度写成固定自由度，则会混淆不同假设。为此，本文以运行级证据组织实验：每一组配对共享主干检查点、测试窗口和掩码，记录分布参数是否参与优化，并将概率头种子与主干种子分开报告。

本文的工作包括三个方面。构建可追溯的固定掩码配对协议，使分布头比较具有明确的输入和检查点对应关系；在三个数据集、两个主干上比较固定重尾分布与 Gaussian，并通过 TimePerceiver 分布消融和多种子结果解释自由度的作用；联合报告概率评分和点误差，保留指标间的权衡，避免用单一胜率替代完整结论。

2 相关研究

2.1 预测表示与概率输出

时间序列 Transformer 的分块表示与通道建模为长历史输入提供了不同的计算路径 [2]。本文使用已训练的 TimePerceiver 和 PatchTST 作为表示来源，概率头阶段冻结主干。研究对象因此是给定表示上的分布选择，而不是两个主干端到端训练能力的排名。

概率预测用分布描述未来变量，评分规则用于评价预测分布与真实观测的一致性。NLL 关注观测处的密度，CRPS 则结合预测分布与观测之间的距离；二者提供互补信息 [3]。重尾分布允许在中心区域与尾部之间作不同于 Gaussian 的概率分配，但这一性质是否转化为更好的预测，需要在相同数据条件下验证。

2.2 缺失历史与受控比较

历史插补与未来预测的评价目标不同。前者重建历史位置，后者估计未发生的目标。本文遮挡历史窗口而保持未来标签不变，并在固定评估资产上比较预测头。该设计将缺失输入引起的变化与测试样本随机重采样分离，所有结论均对应本文定义的输入处理与预测范围。

3 问题定义与分布头

3.1 缺失输入协议

记历史窗口为 $X \in \mathbb{R}^{L\times C}$，未来目标为 $Y \in \mathbb{R}^{H\times C}$，观测掩码为 $M \in \{0,1\}^{L\times C}$，其中 1 表示保留。训练集拟合的归一化变换记为 S，缺失输入为

$$\widetilde{X} = M \odot S(X). \tag{1}$$

缺失位置在标准化空间置零，未来目标不参与掩码生成。预测头输出各时刻、各通道的边际分布；本文的区间指标也对应边际区间，而非整个未来轨迹的联合覆盖。

3.2 匹配位置与尺度映射

令冻结主干产生的表示为 $Z = f_\theta(\widetilde{X})$。各分布头采用相同结构的位置与尺度投影：

$$\mu = W_\mu Z + b_\mu, \tag{2}$$

$$s = \mathrm{softplus}(W_s Z + b_s) + 10^{-4}. \tag{3}$$

这里的“相同”指映射结构和初始化协议，不表示训练后的权重绑定。位置映射由主干的点预测投影初始化；优化器更新概率头参数，主干参数保持冻结。Gaussian、Laplace 与固定 Student-t 具有相同的可训练参数数量，可学习 Student-t 额外引入通道级自由度参数。

Gaussian 使用 $\mathcal{N}(\mu, s^2)$，Laplace 使用位置为 μ、尺度为 s 的分布。Student-t 的密度为

$$p(y) = \frac{\Gamma((\nu+1)/2)}{\Gamma(\nu/2)\sqrt{\nu\pi}s}\left(1+\frac{(y-\mu)^2}{\nu s^2}\right)^{-(\nu+1)/2}. \tag{4}$$

固定版本取 $\nu = 8$；可学习版本按通道使用 $\nu_c = 2.01 + \mathrm{softplus}(a_c)$，初始值为 8。后者不是输入条件化自由度，同一通道的自由度参数在样本之间共享。

Student-t 的方差为 $s^2\nu/(\nu-2)$。因此，匹配尺度投影的结构不等于匹配预测方差；固定 $\nu = 8$ 时，其方差为 $4s^2/3$。本文将这一数学区别与实验观察分开，当前比较不把收益全部归因于尾部形状。

4 实验协议

4.1 数据与证据分组

所有核心结果采用 $L = 384$、$H = 96$、随机缺失率 0.3。ETTh1 包含 7 个数值通道，采用官方 12 个月训练、4 个月验证、4 个月测试的边界。Weather 与 Electricity 分别包含 21 和 321 个数值通道，采用官方 70% 训练、10% 验证、20% 测试划分。验证及测试的历史窗口允许使用边界之前的历史上下文；归一化统计量由训练段拟合。

测试掩码种子固定为 2025，验证掩码种子固定为 43025。训练掩码按已存储的种子规则生成，不读取测试掩码。不同阶段的历史规则保留在运行配置中，本文不将阶段标签本身当成新样本。核心清单共有 42 条阶段引用，去重后为 36 个概率训练运行。

实验分为三组：TimePerceiver 的 Gaussian 与可学习 Student-t 使用 2021、2022、2023、2025 四个概率头种子；TimePerceiver 的四分布消融使用种子 2025；PatchTST 的 Gaussian 与固定 Student-t 使用种子 2025。每个数据集、每个主干内共享对应的固定主干检查点。四个概率头种子不代表四次主干训练，也不作为固定自由度结果的重复试验。

4.2 评价与统计口径

训练采用概率负对数似然，检查点按验证 NLL 选择，不以测试指标早停。NLL、MSE、MAE 在对应官方标准化空间计算。CRPS 定义为

$$\mathrm{CRPS}(F, y) = \mathbb{E}|U - y| - \tfrac{1}{2}\mathbb{E}|U - U'|, \tag{5}$$

其中 U, U' 为来自 F 的独立样本。已有运行采用 64 样本 Monte Carlo 估计与固定评价种子 52025。本稿延续该口径，不将其写成解析 CRPS。

多种子表使用样本标准差，分母为 $n-1$。配对差值统一定义为目标分布头减 Gaussian，负值表示相应误差或评分下降。单种子结果直接报告观测值，不填补标准差。本文报告的均值差异属于描述性统计，不赋予尚未计算的置信区间或显著性。

5 实验结果

5.1 可学习自由度的训练稳定性

表1展示了固定主干上的四概率头种子结果。可学习 Student-t 在三个数据集上的 NLL 和 CRPS 均值均低于 Gaussian。Weather 的平均 NLL 从 0.577226 降至 0.103670，CRPS 从 0.244788 降至 0.207544；相较之下，MSE 的变化为 −0.000488。概率评分与点误差变化幅度不同，表明二者刻画了不同的预测性质。

ETTh1 的 NLL 平均差值为 −0.043900，Electricity 为 −0.074296。Electricity 的 MSE 均值从 0.167419 升至 0.167703，与 NLL 改善方向相反。重尾头的评估因而不能简化为点预测全面优于 Gaussian，也不能由这一点误差变化否定概率评分收益。

Table 1: TimePerceiver 四概率头种子结果：均值 ± 样本标准差。Student-t 为可学习自由度；每个数据集共享一个主干检查点。

数据集	分布头/主干	NLL	CRPS	MSE
ETTh1	Gaussian	0.915014 ± 0.006643	0.342011 ± 0.002338	0.416862 ± 0.003302
ETTh1	Student-t (learned)	0.871113 ± 0.007801	0.337656 ± 0.002124	0.415611 ± 0.002699
Weather	Gaussian	0.577226 ± 0.017061	0.244788 ± 0.003197	0.210306 ± 0.001462
Weather	Student-t (learned)	0.103670 ± 0.020066	0.207544 ± 0.000670	0.209818 ± 0.000964
Electricity	Gaussian	0.439644 ± 0.002139	0.209365 ± 0.000178	0.167419 ± 0.000420
Electricity	Student-t (learned)	0.365348 ± 0.000800	0.207395 ± 0.000338	0.167703 ± 0.000613

Table 2: TimePerceiver 分布消融，种子 2025。所有结果为 random 0.3、$L = 384, H = 96$；单种子不报告标准差。

数据集	分布头/主干	NLL	CRPS	MSE
ETTh1	Gaussian	0.918535	0.344127	0.420332
ETTh1	Laplace	0.879116	0.341785	0.424149
ETTh1	Student-t (fixed 8)	0.864949	0.336548	0.413927
ETTh1	Student-t (learned)	0.877154	0.340263	0.419177
Weather	Gaussian	0.586325	0.245442	0.212237
Weather	Laplace	0.204399	0.209589	0.210051
Weather	Student-t (fixed 8)	0.136165	0.208461	0.210994
Weather	Student-t (learned)	0.129293	0.208276	0.210836
Electricity	Gaussian	0.440598	0.209453	0.167881
Electricity	Laplace	0.370388	0.208768	0.170436
Electricity	Student-t (fixed 8)	0.367009	0.207797	0.168473
Electricity	Student-t (learned)	0.366449	0.207786	0.168486

5.2 固定与可学习自由度

表2将四种分布置于相同的种子 2025 条件下。ETTh1 上固定 Student-t 的 NLL 为 0.864949，低于可学习版本的 0.877154；Weather 和 Electricity 上则由可学习版本取得更低 NLL。固定与可学习自由度之间存在数据集差异，不能由四种子 learned-df 表直接推出固定自由度的稳定性。

与 Gaussian 相比，固定 Student-t 在三个数据集均降低 NLL 和 CRPS。Laplace 也改善了这两项评分，但其 MSE 排序与概率评分并不一致。该结果使研究问题从“是否需要更多参数”进一步转向“哪种分布约束适合给定数据”，因为 Gaussian、Laplace 和固定 Student-t 的位置与尺度映射容量一致。

5.3 第二主干上的配对结果

表3显示固定 Student-t 相对 Gaussian 的变化。六组数据集与主干配对的 NLL、CRPS 差值均为负。PatchTST 的 Weather 配对具有较大的 NLL 变化，本文保留原始差值，不据此推断跨主干的整体排名，因为不同主干的训练器及指标协议标识并不完全相同。

Electricity 上，TimePerceiver 的 MSE 增量为 0.000592，PatchTST 为 0.001980，后者相对增幅约 1.194%。当点预测容许增幅取 1% 时，PatchTST 的这一配对不满足阈值。阈值不改变原始指标，只改变“是否接受该权衡”的决策，因此应与原始差值一同公开。

6 讨论与可复现性

实证结果显示，概率头能够在不更新主干的条件下改变预测分布质量。固定 Student-t 与可学习 Student-t 均提供了正向概率评分证据，但两者回答的问题不同：前者检验预设分布形状，后者同时允许训练调整通道级自由度。把二者合并会掩盖这一机制差别。

方差与尾部形状也应分开解释。当前映射容量对照排除了新增位置或尺度投影参数这一因素，却没有构成预测方差匹配对照。进一步的方差匹配和自由度敏感性实验将用于检验收益来源，而不是回溯修改本稿已报告的对照定义。

复现材料按运行目录保存配置、指标和状态，源检查点与验证、测试掩码通过 SHA256 对应。本轮审计核对了三张核心表的 72 个 NLL、CRPS、MSE 数值，并生成独立结果清单。阶段之间复用的运行不重复计数。原始记录中的继承配置 ID 和缺项另列在审计文件中，不通过修改历史产物消除差异。

本文的核心表对应随机缺失率 0.3 和预测长度 96。其他机制、预测长度与独立主干种子的扩展属于后续验证范围；这一区分决定结论适用的实验条件。时间窗口具有重叠，后续配对统计需

Table 3: 固定 Student-t 减 Gaussian 的配对差值（表中三项均为差值）。种子 2025，random 0.3，$H = 96$。

数据集	分布头/主干	NLL	CRPS	MSE
ETTh1	TimePerceiver	-0.053587	-0.007578	-0.006405
ETTh1	PatchTST	-0.035317	-0.002538	-0.005439
Weather	TimePerceiver	-0.450160	-0.036981	-0.001243
Weather	PatchTST	-1.818698	-0.076205	-0.050179
Electricity	TimePerceiver	-0.073589	-0.001656	+0.000592
Electricity	PatchTST	-0.083433	-0.001688	+0.001980

要考虑时序依赖，不能把窗口内每个元素当作独立重复。

7 结论

本文以固定历史掩码、冻结主干和运行级溯源组织重尾概率预测比较。在三个数据集和两个主干的单种子配对中，固定 Student-t 相对 Gaussian 改善 NLL 与 CRPS；TimePerceiver 的四概率头种子实验进一步支持可学习 Student-t 的平均概率评分收益。Electricity 的点误差权衡与自由度消融表明，分布评分、点预测表现和参数约束需要共同构成结论。该配对框架为后续检验方差匹配、自由度敏感性及更广缺失条件提供了可复核的参照。

References

[1] J. Lee and H. Lee. TimePerceiver: An Encoder-Decoder Framework for Generalized Time-Series Forecasting. NeurIPS, 2025.

[2] Y. Nie, N. H. Nguyen, P. Sinthong, and J. Kalagnanam. A Time Series is Worth 64 Words: Long-term Forecasting with Transformers. ICLR, 2023.

[3] T. Gneiting and A. E. Raftery. Strictly Proper Scoring Rules, Prediction, and Estimation. Journal of the American Statistical Association, 102(477):359–378, 2007.